

大規模言語モデルを用いた批判的論文読解支援システム

方 欣瑞^{1,a)} 徐 安然^{3,1,b)} 楊 期蘭^{1,c)} 林 雅芳^{1,d)} マラクリヤ シルバン^{2,1,e)} 矢谷 浩司^{1,f)}

概要：批判的読解は、研究者が批判的思考力を育成する上での主要な手段である。同僚との意見交換や思考共有はこの読解を強化するが、若手研究者は多様な視点を提供できる仲間にアクセスする機会が限られている。この課題に対処するため、本研究では形成的調査（N = 8）から得られたピアフィードバックに基づき、若手研究者の批判的論文読解を支援するためのその場型思考交流インタフェースを設計した。さらに、2週間にわたり46名の若手研究者を対象に、エージェントなし、単一エージェント、および複数エージェントという3条件下で思考交流の効果を評価した。その結果、読解中にエージェントを介した思考交流を導入することで、エージェントなし条件と比較して参加者の批判的思考スコアが有意に向上した。単一エージェント条件では、参加者は論文内容に対してより多くの内省的注釈を行い、複数エージェント条件では、エージェントの応答に対してより積極的に関与した。質的分析の結果、複数エージェント条件では参加者が複数の視点を比較・分析する様子も確認された。

Designing An LLM-based Interactive System to Support Critical Paper Reading

1. はじめに

学術論文の読解は単なる情報の理解にとどまらず、研究の目的、方法、結果、および貢献を批判的に評価することを要求される知的活動である。この過程では、読者は自らの視点を問い直し、著者の主張の妥当性や限界を検討する必要がある。その際、他者との議論は重要な役割を果たす。仲間との意見交換を通じて、読者は複数の視点から研究を再解釈し、理解を深めるだけでなく、見落としていた論点や代替的な解釈に気づくことができる [1]。

しかし、現実の研究環境においては、同じ論文を読んでいる仲間を見つけることは容易ではない。研究者の関心分野やスケジュールは多様であり、必ずしも一致しないため、建設的な議論の機会は限られている。その結果、多くの研究者は孤立した状態で論文を読み、自らの理解や解釈に依存せざるを得ないという課題が生じている。

この問題に対し、近年注目されているのが、大規模言語モデル（LLM）を基盤とする対話エージェントである。LLMを活用すれば、読者は他者に代わってエージェントと議論を行い、考えを整理したり、異なる視点を得たりすることができる。先行研究では、このような LLM との対話が読解理解の促進 [2]、批判的思考の喚起 [3]、および多様な視点の提示 [4] に寄与することが示されている。さらに、エージェントの数によって、ユーザの認知処理の様相が異なることも報告されている。単一エージェント形式はユーザが一つの論点に集中するのに役立つ一方、複数エージェント形式は、対立意見や多角的な推論を提示し、グループディスカッションに近い議論を再現できる [5]。

このように、エージェントとの思考交流は人間同士の議論を補完しうるが、その形式の違いが論文読解体験や批判的思考に与える影響については十分に理解されていない。特に、単一のエージェントとの一対一の対話が有効なのか、あるいは複数のエージェントによる多様な視点の提示がより深い批判的読解を促すのかは未解明である。

本研究では、この問題を明らかにするため、以下の問いを設定する。

- RQ1. それぞれのエージェント形式は、読者の批判的読解力にどのように影響するか。

¹ 東京大学 Interactive Intelligent Systems Laboratory
² リール大学 Inria センター
³ 理化学研究所
a) xinrui.fang@iis-lab.org
b) anran.xu@riken.jp
c) chilan.yang@iii.u-tokyo.ac.jp
d) yafanglin@iis-lab.org
e) sylvain.malacria@inria.fr
f) koji@iis-lab.org

- RQ2. それぞれのエージェント形式は、読者の批判的読解の習慣や読解戦略にどのように影響するか。

我々はまず8名の参加者による形式的調査を実施し、批判的論文読解を支援するための設計目標を導出した。その知見に基づき、LLMを用いたその場型思考交流インタフェースを開発し、46名の若手研究者を対象として2週間の実験を行った。結果として、単一エージェントおよび複数エージェントのいずれも批判的思考スコアを有意に向上させたが、思考の進め方や認知負荷の側面で異なる傾向を示した。単一形式では応答に対する内省的注釈が促され、複数形式では複数の視点を比較検討する行動が多く見られた。一方で、複数エージェントとの対話は情報量の多さから一部の参加者に負担感を与えることも確認された。これらの結果は、LLMエージェントを活用した批判的読解支援の設計において、エージェント構成の選択が重要であることを示唆している。

2. 関連研究

2.1 批判的思考における多視点・学際的アプローチ

批判的思考は教育や論文読解において不可欠な能力であり、分析・統合・評価といった高次思考を含むとされている [6], [7]。多様な視点の導入はこの能力を高める有効な方法とされ、異なる背景をもつ読者の議論や相互理解を通じて、知識を相対化し批判的に検討する力が養われる [8]。しかし、グループディスカッションの調整には労力がかかり、若手研究者にとって実践機会が限られているという課題がある [9]。

一方で、近年は異分野の知識を統合する学際的研究が重視され、DiscipLink [10] や Selenite [11] など、複数分野の知見を結びつける支援ツールが提案されている。本研究では、これらの知見を踏まえ、AI エージェントを活用して複数の研究分野の観点を統合し、研究者の批判的論文読解を支援するインタフェースを設計・評価することを目的とする。

2.2 AI 支援による批判的論文読解の課題と可能性

近年、論文読解を支援する AI 技術が数多く提案されており、研究者が重要情報を効率的に抽出したり、引用関係から文献間のつながりを把握したりすることを可能にしている [12]。しかし、引用情報や履歴ベースの推薦に依存することで、異分野の知見に触れる機会が減少し、エコーチェンバー的な情報偏りが生じる懸念が指摘されている [10]。また、AI への過度な依存は認知的オフロード (cognitive offloading) を促進し、主体的な思考や学習意欲の低下を招く可能性がある [13], [14]。特に専門知識が十分でない若手研究者は、AI 活用と独立した判断力の育成のバランスを取ることが重要である。

批判的思考を促す読解手法としては、QRAC (Ques-

tion, Read, Answer, Check) 戦略が広く用いられている [15], [16]。読者が自ら問いを立てて理解を深めるこの方法は、AI 生成の質問を動的に取り入れることで効果が高まることが報告されている [9]。しかし、既存研究の多くは単一論文内での理解支援に留まり、多様な視点の獲得という点では依然として課題が残っている。

3. 形式的調査

本研究では、論文読解時のピアディスカッションを支援するインタフェース設計の方向性を探るため、若手研究者を対象に形式的調査を実施した。

3.1 参加者と手続き

著者の人的ネットワークを通じて機縁法により修士課程3名、博士課程5名の計8名 (平均年齢25.5歳, SD = 2.1, 女性1名, 男性7名) を募集した。各参加者には2回のセッション (各60分) への参加に対し6,000円を謝礼として支給した。本調査は所属機関の倫理審査委員会 (IRB) の承認を得て実施した。調査はZoomを用いたオンライン形式で行い、「初期アイデア生成セッション」と「改良セッション」の2回で構成した。各回は導入 (10分)、読解タスク (30分)、インタビュー (20分) から成り、発話内容は録音・書き起こしの上で質的分析を行った。

3.2 初期アイデア生成セッション

初期セッションでは、Google Docs を用いて参加者と実験者が1本の論文を共同で読み、コメントや質問を通じて相互に意見交換を行った。参加者には自由に操作しながら思考過程を言語化するように求めた。その結果、「セッション単位での質問提示」、「異分野の視点からの解釈」、「注釈へのフィードバック」などが特に有用と評価された。これらの知見を基に、批判的読解を支援し、多様な視点の理解を促す初期プロトタイプを設計した。

3.3 改良セッション

次に、初期結果を反映した低忠実度プロトタイプを開発した。このプロトタイプでは、別ウィンドウで論文を読みながら、チャット形式の LLM インタフェースを通じて AI エージェントと対話できるようにした。エージェントは質問生成や回答提示に加え、異分野の観点からハイライトを解釈する機能を持つ。参加者からは、エージェントの応答が論文内容にとどまらず、分野特有の知識や若手研究者向けの助言を示すことが望ましいという意見が得られた。これらの意見は、後続のインタフェース改良方針に直接反映されている。

3.4 設計目標

2回のセッションで得られた質的データを統合し、批判




図 1 ユーザインターフェースはカスタム PDF ビューアと左の *Comment Pane*, 右の *Section Pane* で構成される。ユーザは文をハイライトし、コメントを残し、批判的思考質問を生成し、AI エージェントとの多ターン思考交換に参加できる。

System Intro

的論文読解を支援するための 4 つの設計目標を導出した。

DG1：異分野的な思考交換の促進

参加者の多くは、論文本文の内容にとどまらず異なる視点から意見を交換することが批判的思考の育成に重要であると指摘した。AI エージェントは専門的な理論や思考様式に裏打ちされた発言が求められる一方で、過度に内容から逸脱すると信頼性が損なわれる可能性があるとの意見もあった。

DG2：セクション単位での読解支援

読解開始前に手順や方針を提示するガイダンスの必要性が指摘された。特に各セクションの前に問いを提示することで、独立した内容の理解を深め、思考の「ギャップ」を意識化できるとされた。このような質問提示は批判的思考を促す有効な手法と考えられる。

DG3：読解を妨げない協調的支援

AI エージェントの介入頻度やタイミングは読解の流れを乱さないよう慎重に設計する必要がある。参加者は、ハイライトやコメント中など集中している場面では介入を避けるべきと述べた。一方で、理解が難しい箇所に対して別視点からの解釈を提示することは理解の促進に有効と述べた。

DG4：要点強調によるフォローアップ支援

多くの参加者が、重要文のハイライトなど意識を促す機能を求めた。ただし、過度な提示は主体的読解を妨げる可能性があるため、まず自力で読解・思考した後に「見落とし確認」や追加の洞察を促す形で提示することが望ましい。

4. インターフェース設計

本研究では、LLM 対応の AI エージェントとの短い質疑応答を通じて批判的読解を支援するインタフェース (図 1) を設計した。インターフェースは、PDF ビューアと二種類のサイドパネルで構成され、論文を読みながら並行して思考交換を行える。左側のコメントパネルはユーザのコメントやハイライトを表示し、AI による追加的考察を提供する。右側のセクションパネルは特定セクションについての集中的な議論を支援する。

4.1 コメントパネル

ユーザは文をハイライトし、Goal, Novelty, Method, Result のラベルを選択できる (図 1-E)。コメントも追加可能で、AI エージェントはラベルクリック時に文を再解釈したりコメントに回答したりする (図 1-F1, DG1, DG3)。また、事前に Semantic Reader [12] でタグ付けされた重要文を、ユーザの選択に応じてハイライト表示できる (DG4)。

4.2 セクションパネル

セクションパネルでは、ユーザがセクション単位の自己質問 (QRAC) を通じて批判的思考を行える (DG2)。ユーザが回答を入力すると、AI エージェントが評価・回答を提示し、異なる視点を比較できる (DG1)。さらに、回答修正後には全体的フィードバックを受けられ、必要に応じてセクション内の重要文をハイライトして見落としを確認で

きる (DG4)。

4.3 システム実装

本システムは、PDF 表示とインタラクティブ機能を備えたブラウザベースのウェブアプリとして実装した。フロントエンドは React.js と TypeScript で開発し、Vite でビルド、PDF 表示には React-PDF-Viewer を利用した。バックエンドは Python Flask でサーバ処理と API リクエストを担当する。Grobid [17] により PDF を構造化 XML に変換し、OpenAI Assistants API を通じて文献内容に基づく質問やフィードバック生成を行う。

本システムの主要機能は、批判的思考質問の生成である。CReBot [16] は、生成した質問を what, how, why, how well の 4 カテゴリに分類した。CRiTrainer [9] は、これを文章中に直接答えが述べられている低次思考 (what, how) と、批判的思考の鍵である評価と創造を育む高次思考 (why, how well) に分類した。本研究では CRiTrainer の手法に従い、CReBot データベースから 163 の why/how well 質問を抽出し、GPT-4-turbo による few-shot 学習でセクション特化の質問を生成した。

表 1 生成された批判的思考質問の品質とベースラインとの比較

Criterion	p-value	Score Mean (SD)	
		本研究	CReBot [16]
理解容易性	< .001	4.03 (0.40)	4.44 (0.57)
関連性	< .001	4.29 (0.33)	3.55 (0.43)
重要性	< .001	4.11 (0.41)	3.23 (0.49)
網羅性	< .001	4.06 (0.36)	3.02 (0.47)

生成質問の評価は、理解容易性、関連性、重要性、網羅性の 4 項目で行った。16 本のトップ HCI 会議論文から計 123 質問を生成し、12 名の博士課程研究者が 5 段階評価した。結果として、生成質問は関連性、重要性、網羅性で人手ラベルを上回ったが、理解容易性はやや低く、情報密度や文構造の複雑さが影響したと考えられる (表 1)。

5. ユーザスタディ

本研究では、単一エージェントと複数エージェントによる思考交換が読者の批判的思考能力 (RQ1) および批判的読解行動 (RQ2) に与える影響を評価するため、事前テスト、2 週間の学習フェーズ、事後テストからなる被験者間実験を実施した。参加者はランダムに以下の 3 条件のいずれかに割り当てた：

(1) 単一分野エージェントとの思考交換；(2) 複数分野エージェントとの思考交換；(3) 思考交換インターフェースなし、質問回答のみ静的フィードバックで行う条件。2 週間の期間により、読解行動や批判的思考能力の変化を観察した。本研究は第一著者所属機関の IRB に承認された。

5.1 実験デザイン

参加者は、割り当てられた論文を読み、各条件に応じて批判的思考質問に回答した。質問は、事前・事後テストでは実験者による事前生成質問、学習フェーズではシステム生成質問を使用した。

複数エージェント条件 (MULTI CONDITION)：異分野知識が文献検索やアイデア生成のパフォーマンスを向上させることが知られている [10]。本条件では、LLM プロンプトを用いて異なる分野の AI エージェントを生成し、セクション内容に応じて動的に 3 分野を選択する。ユーザがエージェントをピン留めすると、その分野視点から一貫してフィードバックを提供する。

単一エージェント条件 (SINGLE CONDITION)：固定分野の 1 エージェントと対話する形式で、従来の AI サービスによく見られる 1 対 1 構成である。複数エージェント用の比較・評価機能 (ピン留め、賛成／反対ボタン) は除外した。

エージェントなし条件 (NONE CONDITION)：エージェントとの対話は行わず、静的テキストによる QRAC [15], [16] に基づく回答改善リマインダーのみ提示した。

5.2 参加者

HCI や関連分野 (コンピュータサイエンス、社会学、心理学など) を専攻または関心を持つ 46 名 (平均年齢 = 23.35, SD = 3.74；男性 11 名、女性 33 名、未回答 2 名；修士 27 名、学部 19 名) を募集した。参加者は TOEIC700 以上相当の英語能力を有し、批判的読解未経験者、または自己評価で平均以下の経験者に限定した。15 名ずつを複数・単一エージェント条件に、16 名をエージェントなし条件に割り当てた。参加者は報酬として約 9,600 円相当を受け取った。

5.3 手順

ユーザスタディは以下の 3 段階で構成された：1. 事前テスト (1.5 時間, Day 1) . 2. 2 週間の批判的読解トレーニング (Day 2–15) . 3. 事後テスト (1.5 時間, Day 16) .

トレーニング期間中、各参加者は指定された論文を週 3 本読解し、少なくとも 3 つの批判的思考質問を生成・回答・修正した。回答内容および操作ログは分析のため記録した。使用可能なリソースは指定されたインターフェースと、必要に応じて利用するデジタルライブラリおよび翻訳ツールのみであった。

5.4 事前・事後テスト (RQ1)

それぞれのテストでは、CHI Late-Breaking Work 論文を読解し、各セクションごとに批判的思考質問に回答した。回答は 4 名の HCI 分野の博士が Critical Thinking Value Rubric [18] に基づき 5 項目で評価した。各項目のスコアは 1–4 点で付与し、平均を算出して総合批判的思考スコアとした (図 2)。




図 2 3 グループにおける訓練前後テストでの、Critical Thinking Value Rubric の 5 つの評価次元ごとの外部評価スコアおよび総合平均スコア。

5.5 独自視点数 (RQ1)

2.1 節で述べたように、多角的視点の考慮は批判的思考に重要である [7]。そこで RQ1 に対し、2 週間の訓練期間中に参加者の回答文に含まれる固有視点数を文レベルの意味クラスタリングで分析した。既存研究 [19] に基づき、回答文を文単位に分割し、各文を Sentence Transformer ('paraphrase-MiniLM-L6-v2') で埋め込みベクトルに変換した。次に、K-Means [20] を用いてクラスタリングを行い、慣性値の二次差分が最大となる点 [21] からクラスタ数を決定した。得られたクラスタ数を視点数の指標とし、初回答と修正版の平均視点数を算出した。

5.6 インタラクション行動 (RQ2)

SINGLE CONDITION と MULTI CONDITION の行動差を探索するため、初回答から修正版への変化を分析し、内省的行動の違いを検討した。参加者がフィードバックを基に回答

を改善する平均時間とシステムとのやり取りを計測した。ハイライト、コメント、自動生成ハイライト、および AI コメントを *Annotations*、エージェントのピン留めや引用文献の参照を *Reactions* と定義した。これらを基に各参加者の行動を散布図上に可視化した。

5.7 オープンエンド質問の分析 (RQ2)

事後テストの 3 つのオープンエンド質問について、テーマ分析 [22] を行った。質問 1 では、Bloom のタキシノミー [23] に基づくトップダウン分析と、新たなテーマを抽出するボトムアップ分析を併用した。質問 2 と質問 3 は探索的であったため、事前分類を設けず、ボトムアップのみで参加者の内省や経験を整理した。




図 3 各グループにおける各時点（初回 vs 修正版）の K-means クラスターの平均数。有意水準はアスタリスクで示す：* $p < .05$, ** $p < .01$, *** $p < .001$ 。

6. 結果

6.1 事前・事後テストにおける批判的思考スコア (RQ1)

3 条件 (NONE, SINGLE, MULTI; 被験者間) $\times$ 2 時点 (事前・事後; 被験者内) の整列ランク変換混合計画分散分析を実施した。5 項目および総合の批判的思考スコアの変化は図 2 に示す。

総合スコアでは、事前・事後間で有意な主効果があり、条件とテスト時点の交互作用も有意であった。事後検定の結果、MULTI ($t(14)=6.16, p < .001$, Cohen's $d = 1.28$) と SINGLE ($t(14)=4.65, p < .001$, Cohen's $d = 1.18$) では有意な改善が見られたが、NONE では変化はなかった。事前テスト時点では、3 条件間に有意差はなく、ベースラインは同等であった。

各項目の分析でも、MULTI および SINGLE は全項目で有意に向上した。一方、NONE は「Explanation of issues」項目のみ改善が認められた ($t(15)=2.997, p < .01$, Cohen's $d = 0.67$)。

以上より、2 週間のトレーニングで MULTI および SINGLE は批判的思考能力を向上させ、NONE は変化がほとんどなかったことが示された。

6.2 独自視点数 (RQ1)

2 週間の訓練期間で、計 880 組の有効な初回回答と修正版回答 (NONE : 323, SINGLE : 277, MULTI CONDITION : 280) を収集した。参加者ごとの平均クラスター数 (5.5 節参照) に対して、3 条件 (NONE, SINGLE, MULTI; 被験者間) $\times$ 2 回答タイプ (初回 vs. 修正版; 被験者内) の多因子混合型分散分析を行った。結果 (図 3) として、条件の主効果 ($F[2, 43] = 5.68, p < .01, \eta_p^2 = 0.21$) および時間の主効果 ($F[1, 43] = 23.66, p < .001, \eta_p^2 = 0.35$) が有意であった。事後 Tukey 検定の結果、MULTI CONDITION は NONE




図 4 参加者のインタラクション行動の散布図。縦軸は *Reactions* の平均使用回数、横軸は *Annotations* の平均使用回数を示す。MULTI CONDITION の参加者は反応を多用し注釈をほとんど行わず、15 人中 12 人が注釈を使用しなかった。一方、SINGLE CONDITION では注釈がより多く用いられた。

CONDITION よりクラスター数が多く (差=0.50, $p < .001$), SINGLE CONDITION も同様に NONE CONDITION より多かった (差=-0.39, $p < .01$)。一方、MULTI と SINGLE CONDITION 間には有意差がなかった。これらの結果から、SINGLE および MULTI CONDITION の参加者は NONE CONDITION より多様な視点を生成したことが示唆された。

6.3 インタラクション行動 (RQ2)

参加者が SINGLE CONDITION および MULTI CONDITION において行った *Annotations* (ハイライトやコメント) と *Reactions* (エージェントの固定や引用確認) の頻度を分析した。図 4 は、各参加者の平均的な *Annotation* 数と *Reaction* 数の散布図を示す。ゼロ値を除外してシルエット分析を行った結果、スコアは 0.38 で、中程度の分離が確認された。MULTI CONDITION の 15 人中 12 人が *Annotations* を全く使わず、これは SINGLE CONDITION (4/15) の約 3 倍であった。一方、MULTI CONDITION では *Reactions* が多く、SINGLE CONDITION では *Annotations* が中心であった。

6.4 オープンエンド質問の分析 (RQ2)

NONE CONDITION の参加者は、低レベルの思考スキル (知識、理解、適用) や補助的スキル (読解速度、集中力) の向上を挙げることが多かった。実際、NONE CONDITION の参加者は「読解速度が向上した」「より注意深く読むようになった」(NP2) と述べていた。

対照的に、MULTI CONDITION および SINGLE CONDITION の参加者は、低レベルに加えて、低レベルの思考スキル (分析、統合、評価) の向上をより頻繁に報告した。例えば、MULTI CONDITION の参加者は「専門家として設計された AI からの提案やコメントに目を通した。それらは私の回答に関連する情報を評価しており、回答の質や分かりやす

さを向上させるために取り入れられるものだった」(MP8)と述べている。この違いは、批判的思考能力の向上において MULTI CONDITION および SINGLE CONDITION が NONE CONDITION 条件を上回った理由を部分的に説明するものと考えられる。

さらに、分析スキルの向上に言及した参加者数は、SINGLE CONDITION (2/15) よりも MULTI CONDITION (8/15) の方が多かった。例えば「とくに研究論文を分析する読解スキルが大幅に向上した」(MP2) という記述がみられた。

7. 考察

7.1 エージェントのフィードバック統合による批判的思考の促進 (RQ1)

ユーザスタディの結果、AI エージェントとの思考交換 (MULTI および SINGLE CONDITION) は、参加者の批判的思考能力の向上 (Section 6.1), および多様な視点の生成 (Section 6.2) に寄与することが示された。特に、若手研究者に対して有効であることが確認され、本研究の主要な目的と一致する。

これらの結果は、LLM を効率化だけでなく、思考交換を通じて学習支援に活用できることを示す。従来の LLM 支援ツールは情報検索や文献整理の効率化に重点を置き、高次思考の発達を阻害する可能性が指摘されている [24], [25]。本研究では、エージェントが回答の広がりや深さを問いかけることで、参加者が思考を修正したり反省したりする機会を提供し、能動的な批判的思考を促す設計となっている。

さらに、本研究の結果は、グループ読解における多様な視点の交換が理解力や批判的思考を高めることを示した先行研究と一致する [26]。LLM エージェントはピアの存在を模擬し、読解中に異なる視点を考慮する契機を提供できる。この手法は、非同期学習や異分野・異文化間の協働など、直接交流の機会が限られる状況にも応用可能である。

7.2 単一 vs. 複数 AI エージェントの読解行動への影響 (RQ2)

ユーザスタディの結果 (6.3 節) から、思考交換の条件が参加者の読解行動に影響することが明らかになった。MULTI CONDITION の参加者は主に複数の AI エージェントの回答を分析することに注力したのに対し、SINGLE CONDITION の参加者は AI エージェントのコメントを論文内容と統合する形で活用する傾向が見られた。これは、今後のインターフェース設計において、読解中の認知活動を促すために様々な設定が有効であることを示唆する。例えば、複数エージェントは論文外の関連情報の抽出に適しており、一対一の設定は論文内容の理解と整理に適していると考えられる。

定量的な有効性の差は明確ではなかったが、MULTI CONDITION の参加者は分析スキルの向上を実感していたこと

がオープンエンド質問から明らかになった。15 人中 8 人が *Analysis* 能力の向上を報告し、SINGLE CONDITION より 4 倍多かった。*Analysis* は Bloom のタクソノミー [23] における高次認知プロセスであり、情報を分解・比較する能力で批判的思考に不可欠である。複数エージェントと同時にやり取りし、*pin* や *thumb up/down* の反応を行うことで、異なるコメントを比較・分析する認知活動が促されたと考えられる。これは複数エージェント思考交換インターフェースの独自の利点を示している。

これに対し、フィードバック形式やプロンプトは同じでエージェント数のみが異なることから、思考交換に関わるエージェント数がユーザ体験に影響することが示唆される。認知負荷の高いタスクでは、複数エージェントがネガティブ感情を引き起こす場合があるが、単一エージェントのコメントは処理が容易である。これは、複数エージェントシステムが必ずしも単一エージェントより優れないことを示す先行研究 [27] と一致する。今後の研究では、複数エージェントの利点を活かしつつ、ユーザに過度な負荷を強くないようにする設計戦略の検討が必要である。例えば、タスクの難易度に応じて段階的に複数の視点を導入することで、多様な洞察を保ちながら認知負荷を抑えることが可能である。

8. 終わりに

本研究では、LLM を用いた学術論文読解支援のためのその場思考交換インターフェースを提案し、模擬的なピアフィードバックを統合することで批判的読解能力を向上させることを目指した。混合手法によるユーザスタディの結果、以下が示された。

- AI エージェントを介した思考交換を読解過程に取り入れることで、若手研究者の批判的思考能力が向上すること。
- 参加するエージェントの数が、読者の批判的読解行動に異なる影響を与えること。

具体的には、単一エージェントとやり取りした参加者は、AI の応答を確認した後、自身の考えを振り返る手段としてテキスト上に直接注釈を行う傾向があった。一方、複数エージェントとやり取りした参加者は、AI エージェントが示す異なる視点を比較・分析することに主眼を置き、テキスト上への直接的な注釈はあまり行わなかった。

本研究の貢献は、ユーザが思考の負荷を単に AI に委ねるのではなく、読解により多くの認知的努力を投資するよう促す LLM 設計の提案にある。

参考文献

- [1] Keller, R. K., Lajoie, R., Madhavji, N. H., Bruckhaus, T. F., Toubache, K., Hong, W.-K. and El Emam, K.: A Comprehensive Process Model for Studying Software Process Papers, *Proceedings of the 15th International Conference on Software Engineering (ICSE)*

- 1993), IEEE, pp. 78–88 (1993).
- [2] Schmucker, R., Xia, M., Azaria, A. and Mitchell, T.: Ruffle&Riley: Insights from Designing and Evaluating a Large Language Model-Based Conversational Tutoring System, *Artificial Intelligence in Education: 25th International Conference, AIED 2024, Recife, Brazil, July 8–12, 2024, Proceedings, Part I*, Berlin, Heidelberg, Springer-Verlag, pp. 75–90 (2024).
 - [3] Tanprasert, T., Fels, S. S., Sinnamon, L. and Yoon, D.: Debate Chatbots to Facilitate Critical Thinking on YouTube: Social Identity and Conversational Style Make a Difference, *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems (CHI '24)*, CHI '24, New York, NY, USA, Association for Computing Machinery (2024).
 - [4] Zhang, Y., Sun, J., Feng, L., Yao, C., Fan, M., Zhang, L., Wang, Q., Geng, X. and Rui, Y.: See Widely, Think Wisely: Toward Designing a Generative Multi-agent System to Burst Filter Bubbles, *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems (CHI '24)*, CHI '24, New York, NY, USA, Association for Computing Machinery (2024).
 - [5] Clarke, C., Krishnamurthy, K., Talamonti, W., Kang, Y., Tang, L. and Mars, J.: One Agent Too Many: User Perspectives on Approaches to Multi-agent Conversational AI, *arXiv preprint arXiv:2401.07123* (2024).
 - [6] Abrami, P. C., Bernard, R. M., Borokhovski, E., Wade, A., Surkes, M. A., Tamim, R. and Zhang, D.: Instructional interventions affecting critical thinking skills and dispositions: A stage 1 meta-analysis, *Review of educational research*, Vol. 78, No. 4, pp. 1102–1134 (2008).
 - [7] Dekker, T. J.: Teaching critical thinking through engagement with multiplicity, *Thinking Skills and Creativity*, Vol. 37, p. 100701 (2020).
 - [8] Tsui, L.: Fostering critical thinking through effective pedagogy: Evidence from four institutional case studies, *The journal of higher education*, Vol. 73, No. 6, pp. 740–763 (2002).
 - [9] Yuan, K., Lin, H., Cao, S., Peng, Z., Guo, Q. and Ma, X.: CriTrainer: An Adaptive Training Tool for Critical Paper Reading, *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, UIST '23, New York, NY, USA, Association for Computing Machinery (2023).
 - [10] Zheng, C., Zhang, Y., Huang, Z., Shi, C., Xu, M. and Ma, X.: DiscipLink: Unfolding Interdisciplinary Information Seeking Process via Human-AI Co-Exploration, *Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology*, UIST '24, New York, NY, USA, Association for Computing Machinery (2024).
 - [11] Liu, M. X., Wu, T., Chen, T., Li, F. M., Kittur, A. and Myers, B. A.: Selenite: Scaffolding Online Sensemaking with Comprehensive Overviews Elicited from Large Language Models, *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, CHI '24, New York, NY, USA, Association for Computing Machinery (2024).
 - [12] Fok, R., Kambhamettu, H., Soldaini, L., Bragg, J., Lo, K., Hearst, M., Head, A. and Weld, D. S.: Scim: Intelligent Skimming Support for Scientific Papers, *Proceedings of the 28th International Conference on Intelligent User Interfaces*, IUI '23, New York, NY, USA, Association for Computing Machinery, p. 476–490 (2023).
 - [13] Gerlich, M.: AI Tools in Society: Impacts on Cognitive Offloading and the Future of Critical Thinking, *Societies*, Vol. 15, No. 1, p. 6 (2025).
 - [14] Lee, H.-P. H., Sarkar, A., Tankelevitch, L., Drosos, I., Rintel, S., Banks, R. and Wilson, N.: The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers, *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, CHI '25, New York, NY, USA, Association for Computing Machinery (2025).
 - [15] Keshav, S.: How to read a paper, *SIGCOMM Comput. Commun. Rev.*, Vol. 37, No. 3, p. 83–84 (2007).
 - [16] Peng, Z., Liu, Y., Zhou, H., Xu, Z. and Ma, X.: CReBot: Exploring interactive question prompts for critical paper reading, *Int. J. Hum.-Comput. Stud.*, Vol. 167, No. C (2022).
 - [17] : GROBID, <https://github.com/kermitt2/grobid> (2008–2025).
 - [18] of American Colleges, A. and Universities: Critical Thinking Value Rubric (2009). Accessed: 2025-04-03.
 - [19] Pasch, S. and Ha, S.-Y.: Human-AI Interaction and User Satisfaction: Empirical Evidence from Online Reviews of AI Products, *International Journal of Human-Computer Interaction*, pp. 1–22 (2025).
 - [20] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. and Duchesnay, E.: Scikit-learn: Machine learning in Python, *Journal of Machine Learning Research*, Vol. 12, pp. 2825–2830 (2011).
 - [21] Kodinariya, T. M. and Makwana, P. R.: Review on determining number of Cluster in K-Means Clustering, *International Journal of Advance Research in Computer Science and Management Studies*, Vol. 1, No. 6, pp. 90–95 (2013).
 - [22] Braun, V. and Clarke, V.: Using thematic analysis in psychology, *Qualitative Research in Psychology*, Vol. 3, No. 2, pp. 77–101 (2006).
 - [23] Bloom, B. S., Engelhart, M. D., Furst, E. J., Hill, W. H., Krathwohl, D. R. et al.: *Taxonomy of educational objectives: The classification of educational goals. Handbook 1: Cognitive domain*, Longman New York (1956).
 - [24] Carr, N.: *The shallows: What the Internet is doing to our brains*, WW Norton & Company (2020).
 - [25] Sparrow, B., Liu, J. and Wegner, D. M.: Google effects on memory: Cognitive consequences of having information at our fingertips, *science*, Vol. 333, No. 6043, pp. 776–778 (2011).
 - [26] Kamin, C., O'Sullivan, P. and Deterding, R.: Does Project LIVE Case Modality Impact Critical Thinking in PBL Groups?. (2002).
 - [27] Pan, M. Z., Cemri, M., Agrawal, L. A., Yang, S., Chopra, B., Tiwari, R., Keutzer, K., Parameswaran, A., Ramchandran, K., Klein, D., Gonzalez, J. E., Zaharia, M. and Stoica, I.: Why Do Multiagent Systems Fail?, *ICLR 2025 Workshop on Building Trust in Language Models and Applications* (2025).